Kriterien für die Lesbarkeitsanalyse

Die folgenden 5 Kriterien sind in der Literatur[1] durch empirische Analyse als für die Lesbarkeit bedeutsam befunden worden. Die Beschreibung zur Berechnung des Kriteriums aus den zu erhebenden Features enthält außerdem eine tabellarische Auswertung der Testergebnisse, die zur Ermittlung der Grenzwerte der Feature-Werte genutzt wurden. Dabei beschreibt der Mittelwert der min-Werte für einfache Texte die untere Grenze und der Mittelwert der max-Werte für schwere Texte die obere Grenze (außer bei *Komplexität der Vokabeln*). Werte oberhalb/unterhalb dieser Grenzen werden auf das jeweilige Minimum/Maximum geclipt.

Wird die Farbkodierung adaptiv in Bezug auf den zugrundeliegenden Maßstab für die Normalisierung (vgl. Figure 2 im Paper) implementiert, überlappen sich vermutlich die Werte des längsten Wörter in den leicht lesbaren Texten mit den Werten der kürzesten Wörter in den schwer lesbaren Texten. Es ist generell zu diskutieren, ob dieser Umstand in der Farbkodierung reflektiert werden sollte oder ob dies die Interpretation der Analyseergebnisse nicht sogar erschwert.

Wortlänge

Hierfür wird zunächst die durchschnittliche Wortlänge analysiert und normiert. Sei W die Menge aller Wörter w_i im zu analysierenden Text mit Wortlänge $|w_i|$. Die minimale Wortlänge ist 1 (bzw. 2 im Deutschen), die maximale ist $|w_i|_{max} = max(|w_i|)$ bzgl. aller Wörter $w_i \in W$.

Der Lesbarkeitswert jedes Wortes wird normiert durch $\frac{|w_i|}{|w_i|_{max}}$ und der summierte Wert der Wörter des entsprechenden Satzes durch die Anzahl der Wörter $|W|$ geteilt. Anschließend wird der Wert z.B. auf Farbwerte zwischen blau $(32, 62, 181)$, weiß und rot $(186, 57, 44)$ abgetragen.

$$\text{Wortlänge-Wert: } \frac{1}{|W|} \cdot \sum_i \frac{|w_i| - 2}{4}$$

Skala

Text	min	max	avg
it_could_happen	3.25	5.66	4.29
the_halloween_house	2.00	9.00	4.10
the_little_gingerbread_man	2.50	6.33	4.17
who_did_patricks_homework	2.00	6.00	3.84

} untere Grenze: $\overline{min} = 2.4375 \approx 2$

Tabelle 1: Wortlänge: einfache Texte

Text	min	max	avg
black_and_white	3.50	6.15	5.00
fight_terrorism	3.72	6.50	5.04
jura_paper	4.52	6.94	5.55
paper_medicine	3.06	7.55	5.13
poems	2.00	4.86	3.47
political_english_text	3.50	5.91	4.85

} obere Grenze: $\overline{max} = 6,3183 \approx 6$

Tabelle 2: Wortlänge: schwere Texte

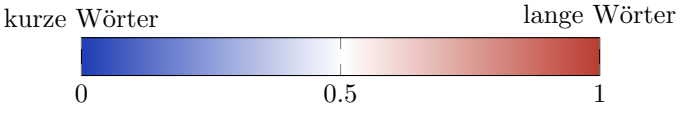

[1] http://bib.dbvis.de/uploadedFiles/305.pdf

Komplexität der Vokabeln

Hier wird der Prozentanteil eines Absatzes/Satzes gemessen, der nicht in einer Liste häufig verwendeter Wörter vorkommt. Dazu kann entweder Wikipedia[2] (deutsch/englisch), ein Korpus aus Zeitungsartikeln[3] oder evtl. eine fachspezifische Textsammlung ausgewertet werden. Der Anteil der Wörter w_i, die nicht in der Liste L sind, wird dann durch die Anzahl $|W|$ der Wörter im zu analysierenden Text W geteilt.

Das Ergebnis ist also **inhärent normiert**, die Tests dienen nur der subjektiven Überprüfung der Güte der Aussagekraft des entsprechenden Wertes.

$$\text{Vokabelkomplexitäts-Wert: } \frac{|w_i \notin L|}{|W|}$$

Skala

Text	min	max	avg
it_could_happen	0.20	0.75	0.41
the_halloween_house	0.00	1.00	0.42
the_little_gingerbread_man	0.00	0.75	0.37
who_did_patricks_homework	0.00	0.75	0.37

} untere Grenze: 0.00

Tabelle 3: Komplexität der Vokabeln: einfache Texte

Text	min	max	avg
black_and_white	0.08	0.75	0.54
fight_terrorism	0.14	0.71	0.49
jura_paper	0.24	0.68	0.50
paper_medicine	0.47	0.93	0.73
poems	0.00	0.64	0.32
political_english_text	0.16	0.64	0.45

} obere Grenze: 1.00

Tabelle 4: Komplexität der Vokabeln: schwere Texte

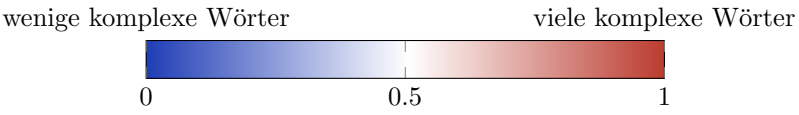

[2] https://en.wiktionary.org/wiki/Wiktionary:Frequency_lists#German
[3] http://wortschatz.uni-leipzig.de/html/wliste.html

Nominalisierungskomplexität

Die Nominalisierung ist die Bildung eines Substantivs aus einer anderen Wortart, vor allem aus Verben und Adjektiven (z.B. *das Böse, etwas Hübsches; the evil, something pretty*). Ein Gerundium ist ein substantivierter Infinitiv eines Verbs (z.b. ***climbing** is dangerous; **das Klettern** ist gefährlich*).

Da Nominalisierungen schwer grundsätzlich vermeidbar sind, die Lesbarkeit des Textes aber auch nicht zwingend schwer unter ihrer Verwendung leidet (z.B. *Es geschah aus **Versehen**; The **use** of drugs is dangerous*), muss die Bewertungsskala kontextsensitiv angelegt werden[4]. Bei einem wissenschaftlichen Fachartikel wird die Lesbarkeit bzgl. dieses Kriteriums evtl. zugunsten einer präzisen Formulierung vernachlässigt, in der Unterhaltungsliteratur wiederum als Stilmittel, etwa um eine Gesinnung über eine bestimmte Ausdrucksweise zu transportieren. Generell sind Texte mit vielen Verben leichter verständlich als Sätze mit wenigen.

Die Berechnung der Nominalisierungskomplexität ergibt sich aus dem Verhältnis von Verben zu Nomen und der geschätzten Anzahl Nominalisierungen. Diese wird anhand der Endung des Wortes (z.B. -tion, -ity, ...) ermittelt. Das entsprechende Nomen wird doppelt gezählt (Anzahl der Nominalisierungen wird zur Anzahl der Nomen addiert), um ihm mehr Gewicht zu verleihen.

$$\text{Nominalisierungskomplexität: } \frac{|Verben|}{|Nomen| + |Nominalisierungen|}$$

Achtung! Hier ist ausnahmsweise ein höherer Wert besser als ein kleiner! Für die Visualisierung wird daher der normierte Kehrwert zurückgegeben.

$$\text{Nominalisierungskomplexitäts-Wert: } 1 - \frac{1}{4} \cdot \frac{|Verben|}{|Nomen| + |Nominalisierungen|}$$

Skala

Text	min	max	avg
it_could_happen	0	5	1.00
the_halloween_house	0	4	0.76
the_little_gingerbread_man	0	5	1.29
who_did_patricks_homework	0	3	1.10

} obere Grenze: $\overline{max} = 4.25 \approx 4$

Tabelle 5: Nominalisierungen: einfache Texte

Text	min	max	avg
black_and_white	0	3	0.45
fight_terrorism	0.14	2.00	0.58
jura_paper	0.00	1.40	0.49
paper_medicine	0.00	0.75	0.33
poems	0.00	3.00	1.08
political_english_text	0.00	1.33	0.46

} untere Grenze: $\overline{min} = 0.023 \approx 0$

Tabelle 6: Nominalisierungen: schwere Texte

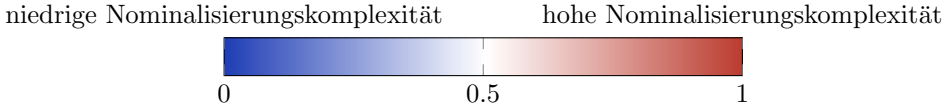

[4] `https://ps.ipd.kit.edu/backend/index.php/veroeffentlichungen-details/items/3801.html`

Satzlänge

Hier wird die Anzahl der Wörter $|W|$ in einem Satz gemessen. Der experimentell ermittelte Höchstwert von 100 Wörtern pro Satz verzerrt die Ergebnisse sehr stark. Die Literatur [5] bestätigt diesen subjektiven Eindruck. Daher wird ein Höchstwert von 29 verwendet, der sich auch in der avg-Spalte von Tabelle 8 wiederfindet.

önnten entsprechende Werte aus anderer Literatur[6] für die Maßstabsfindung übernommen werden, was jedoch in je nach Kontext (nicht berücksichtige Textarten, Sprachwandel) zu weniger aussagekräftigen Ergebnissen führen könnte.

$$\text{Satzlänge-Wert: } \frac{|W| - 2}{27}$$

Skala

Text	min	max	avg
it_could_happen	3	42	18.00
the_halloween_house	1	26	9.68
the_little_gingerbread_man	1	31	10.91
who_did_patricks_homework	2	21	10.00

} untere Grenze: $\overline{min} = 1.75 \approx 2$

Tabelle 7: Satzlänge: einfache Texte

Text	min	max	avg
black_and_white	4	81	26.65
fight_terrorism	11	52	25.49
jura_paper	6	74	29.60
paper_medicine	8	101	28.83
poems	2	54	17.22
political_english_text	6	39	19.15

} tatsächliche Grenze: 29 (siehe Beschreibung oben)

Tabelle 8: Satzlänge: schwere Texte

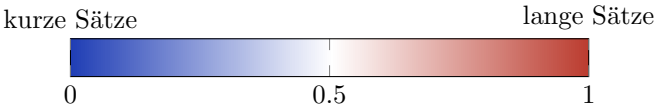

[5] BASTABLE, Susan B., et al. Health professional as educator: principles of teaching and learning, S. 577. Jones & Bartlett Publishers, 2010.

[6] `https://de.wikipedia.org/wiki/Satzl%C3%A4nge#Durchschnittliche_Satzl.C3.A4nge`

Komplexität der Satzstruktur

Dieses Kriterium basiert auf der Annahme, dass der für das Verständnis eines Satzes erforderliche mentale Arbeitsaufwand mit dem Grad an Verschachtelung und der Verwendung von Klammern steigt.

Der dem Maßstab zugrundeliegende Verzweigungsfaktor des Satzstruktur-Baums muss zunächst experimentell ermittelt werden. Um Mehrdeutigkeiten aufzulösen, wird der Stanford Parser[7] verwendet. Dieser hat auch eine eingebaute Visualisierungsmöglichkeit für den entstehenden Syntaxbaum.

$$\text{Verschachtelungswert: } \frac{Baumtiefe - 4}{15}$$

Skala

Text	min	max	avg
it_could_happen	5	21	10.00
the_halloween_house	3	17	6.74
the_little_gingerbread_man	3	19	8.08
who_did_patricks_homework	4	17	7.36

untere Grenze: $\overline{min} = 3.75 \approx 4$

Tabelle 9: Komplexität der Satzstruktur: einfache Texte

Text	min	max	avg
black_and_white	4	23	11.84
fight_terrorism	7	25	13.00
jura_paper	3	26	14.00
paper_medicine	3	11	5.83
poems	3	10	5.78
political_english_text	5	19	11.12

obere Grenze: $\overline{max} = 19$

Tabelle 10: Komplexität der Satzstruktur: schwere Texte

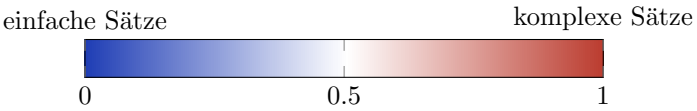

Erläuterung

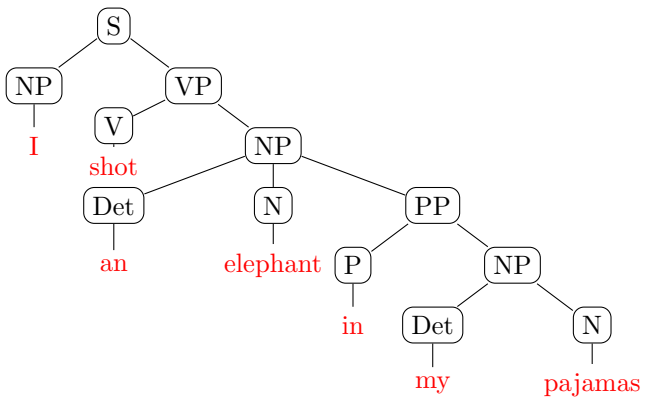

Abbildung 1: Beispiel 1 für Mehrdeutigkeit, 6 Level

[7] http://nlp.stanford.edu/software/lex-parser.shtml

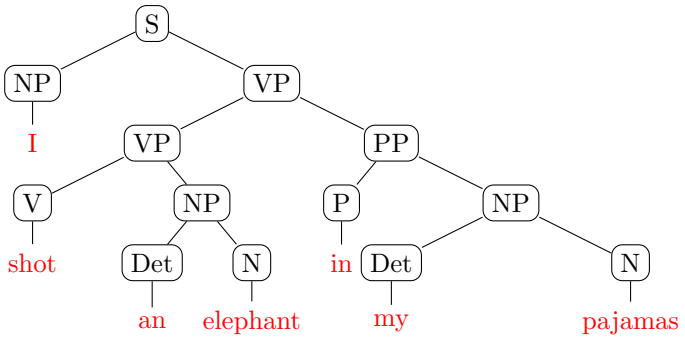

Abbildung 2: Beispiel 2 für Mehrdeutigkeit, 5 Level

Symbol	Bedeutung	Beispiel
S	sentence	the man walked
NP	noun phrase	a dog
VP	verb phrase	saw a park
PP	prepositional phrase	with a telescope
Det	determiner	the
N	noun	dog
V	verb	walked
P	preposition	in